

ОТЧЁТ О ПРОДЕЛАННОЙ РАБОТЕ

МАГИСТРАНТА

ФИО обучающегося:	Маратов Ерасыл Балканович
Образовательная программа:	ВТиПО (Вычислительная техника и программное обеспечение)
Дисциплина:	Системы компьютерного моделирования и проектирования

Астана, 2026

1. ВВЕДЕНИЕ

Настоящий отчёт отражает результаты практической работы, выполненной в летнем семестре в рамках дисциплины «Системы компьютерного моделирования и проектирования». Работа посвящена проблеме автоматической обработки и анализа данных магнитно-резонансной томографии (МРТ) коленного сустава с применением методов машинного обучения.

В процессе выполнения работа прошла два принципиально различных этапа. На **первом этапе** была сформулирована исходная задача — многоклассовая классификация степени остеоартрита по шкале Kellgren–Lawrence с использованием публично доступного датасета МРТ-снимков хряща коленного сустава. На **втором этапе**, после получения реального клинического датасета KneeMRI-Meniscus-Dataset, в ходе его детального анализа были выявлены фундаментальные несоответствия между новыми данными и изначальной постановкой задачи. Это потребовало пересмотра постановки задачи, адаптации признакового пространства, переобучения модели и её интеграции в веб-приложение.

Актуальность работы обусловлена высокой распространённостью повреждений мениска коленного сустава в клинической практике. Автоматизированная диагностика по данным МРТ позволяет сократить время интерпретации снимков, снизить субъективность врачебных оценок и обеспечить поддержку принятия клинических решений.

2. ИЗНАЧАЛЬНАЯ ПОСТАНОВКА ЗАДАЧИ И ПЕРВОНАЧАЛЬНЫЙ ДАТАСЕТ

2.1. Первоначальная задача: классификация степени остеоартрита

На начальном этапе работы была поставлена задача **многоклассовой классификации степени остеоартрита коленного сустава по шкале Kellgren–Lawrence (KL)**. Данная шкала является стандартом в клинической радиологии и включает пять градаций тяжести патологии (таблица 1).

Таблица 1 — Градации шкалы Kellgren–Lawrence, используемые в исходной постановке задачи

Класс	Обозначение	Клиническое описание
0	KL-0 (Норма)	Отсутствие признаков остеоартрита
1	KL-1 (Сомнительный)	Сомнительное сужение суставной щели, возможные остеофиты
2	KL-2 (Лёгкий)	Определённые остеофиты, возможное сужение суставной щели
3	KL-3 (Умеренный)	Множественные остеофиты, определённое сужение суставной щели, склероз
4	KL-4 (Тяжёлый)	Выраженные остеофиты, значительное сужение суставной щели, тяжёлый склероз

Исходная задача относилась к категории задач компьютерного зрения,

ориентированных на анализ **сагиттальных проекций** МРТ-снимков, где хорошо визуализируются суставная щель, хрящ, остеофиты и субхондральный склероз — структуры, непосредственно определяющие степень остеоартрита.

2.2. Первоначальный датасет и признаковое пространство

В качестве данных для первоначальной разработки планировалось использование датасета МРТ-снимков хряща коленного сустава, доступного через платформу Kaggle (*3D Knee MRI Cartilage Segmentation*). Данный датасет организован по принципу иерархии классов остеоартрита: изображения распределены по папкам `train/val/test/{0,1,2,3,4}`, где цифра соответствует степени KL. Снимки выполнены в сагиттальной проекции в формате PNG, одноканальные (grayscale).

Для данной задачи было сформировано признаковое пространство из 20 характеристик, среди которых **15 универсальных текстурных признаков** (статистики гистограммы, GLCM-признаки, частотные и градиентные характеристики) и **5 признаков, специфичных для остеоартрита**: отношение площади кости (*bone_area_ratio*), отношение площади хряща (*cartilage_area_ratio*), ширина суставной щели (*joint_space_width*), счёт остеофитов (*osteophyte_score*) и индекс склероза (*sclerosis_index*). Данные признаки имеют прямую клиническую интерпретацию в контексте диагностики остеоартрита и вычислялись на основе морфологического анализа структур, видимых в сагиттальной проекции.

2.3. Первоначальная модель и её ограничения

В качестве классификатора использовался метод случайного леса (Random Forest) с 300 деревьями, обученный на 20 признаках. Целевой переменной служила степень KL (0–4). Ввиду ограниченной доступности реальных размеченных данных значительная часть обучения производилась на синтетически сгенерированных признаках, имитирующих статистические распределения, характерные для каждой степени остеоартрита. В качестве дополнительного инструмента был реализован алгоритм двойного порога Оцу с морфологической постобработкой для **сегментации** хряща и кости на сагиттальных МРТ-снимках с последующей визуализацией в веб-приложении FastAPI.

Таким образом, к моменту получения реального клинического датасета в рамках проекта уже функционировала система, включавшая: модуль сегментации (двойной метод Оцу), веб-интерфейс с визуализацией и модель классификации степени остеоартрита. Именно с этой базой предстояло сопоставить поступившие реальные данные.

3. ПЕРЕФОРМУЛИРОВАННАЯ ЗАДАЧА: ЦЕЛИ И ЗАДАЧИ РАБОТЫ

После детального анализа поступившего датасета (см. раздел 4) стало очевидным, что прямое применение существующей системы к новым данным невозможно ввиду принципиального несоответствия фото разреза коленного сустава, проекций снимков и характера разметки. В связи с этим была сформулирована **новая цель работы**: разработка и интеграция системы **бинарной классификации надрыва мениска** коленного сустава на основе

реальных МРТ-данных.

Задачи переформулированной работы:

1. Провести всесторонний анализ поступившего датасет.
2. Адаптировать признаковое пространство: исключить
ОА-специфические признаки, разработать признаки, информативные
для диагностики надрыва мениска.
3. Переобучить классификатор для решения бинарной задачи (класс 0 —
нормальный мениск, класс 1 — надрыв мениска).
4. Оценить качество переобученной модели на реальных клинических
данных.
5. Интегрировать разработанный классификатор в существующее
веб-приложение.

4. РЕАЛЬНЫЙ ДАТАСЕТ KNEEMRI-MENISCUS-DATASET: АНАЛИЗ И СРАВНЕНИЕ

4.1. Общая характеристика датасета

Полученный реальный датасет KneeMRI-Meniscus-Dataset содержит МРТ-снимки коленного сустава с **бинарной разметкой на уровне изображений**: класс 0 — нормальный мениск, класс 1 — наличие надрыва мениска. Датасет состоит из двух частей: оригинальных снимков и аугментированных копий (таблица 2).

Таблица 2 — Состав датасета KneeMRI-Meniscus-Dataset

Директория	Клас с	Описание	Кол-во изображений
Original/0	0	Мениск без патологии (норма)	1 000
Original/1	1	Наличие надрыва мениска	1 000
Augmented/0	0	Аугментированные снимки нормального мениска	1 000
Augmented/1	1	Аугментированные снимки с надрывом мениска	1 000
ИТОГО			4 000

4.2. Форматы и статистика изображений

В ходе программного анализа посредством библиотек PIL и NumPy установлено: формат файлов — PNG, тип данных uint8, диапазон значений 0–255. Оригинальные снимки — полутоновые (grayscale), аугментированные — в режиме RGB. Пространственное разрешение крайне вариативно: выявлено 67 различных размеров (таблица 3).

**Таблица 3 — Распределение наиболее часто встречающихся разрешений
(оригинальная выборка)**

Разрешение, пиксели	Кол-во изображений	Доля, %
512 × 512	835	41,8

Разрешение, пиксели	Кол-во изображений	Доля, %
576 × 576	371	18,6
320 × 320	191	9,6
384 × 384	161	8,1
288 × 288	57	2,9
Прочие (62 варианта)	385	19,3
ИТОГО	2 000	100,0

4.3. Сравнительный анализ двух датасетов

Для наглядного представления фундаментальных различий между первоначальным и реальным датасетами приводится сравнительная таблица по ключевым параметрам (таблица 4).

Таблица 4 — Сравнение первоначального и реального датасетов

Параметр	Первоначальный датасет (Kaggle OA Cartilage)	Реальный датасет (KneeMRI-Meniscus)
Клиническая задача	Оценка степени остеоартрита	Выявление надрыва мениска

Параметр	Первоначальный датасет (Kaggle OA Cartilage)	Реальный датасет (KneeMRI-Meniscus)
Тип классификации	Многоклассовая (5 классов: KL 0–4)	Бинарная (2 класса: норма / надрыв)
Анатомическая проекция	Сагиттальная (боковое сечение)	Аксиальная / коронарная (поперечное сечение)
Структуры в кадре	Суставная щель, хрящ, остеофиты, субхондральная кость	Менисковая ткань, мягкие ткани сустава
Маски сегментации	Предусмотрены (пиксельная разметка)	Отсутствуют (только метки классов)
Объём данных	Ограниченный (загрузка через Kaggle API)	4 000 изображений (2 000 ориг. + 2 000 аугм.)
Разрешение изображений	Стандартизированное	Вариативное (67 различных размеров)
Цветовой режим	Grayscale (одноканальный)	Смешанный: grayscale (ориг.) + RGB (аугм.)
Совместимость с исходной моделью	Полная	Несовместим напрямую

5. ВЫЯВЛЕННЫЕ ПРОБЛЕМЫ И ОГРАНИЧЕНИЯ ИСХОДНОЙ

ПОСТАНОВКИ ЗАДАЧИ

Систематизированный анализ несоответствий между двумя датасетами позволил выявить следующие принципиальные проблемы, исключавшие прямое применение исходной системы к новым данным.

5.1. Несоответствие анатомической проекции. Алгоритм двойного порога Оцу разрабатывался для сагиттальных проекций, где суставная щель, хрящ и кости имеют предсказуемое пространственное расположение. Снимки мениска выполнены в аксиальной и коронарной проекциях: структуры в кадре качественно иные, их яркостное распределение не соответствует ожиданиям алгоритма сегментации. Это исключает возможность получения значимых результатов сегментации и их количественной оценки.

5.2. Отсутствие масок сегментации. Исходный датасет предусматривал пиксельную разметку, позволявшую вычислять метрики Dice coefficient и IoU. Реальный датасет содержит только бинарные метки на уровне целого изображения. Задача сегментации с обучением с учителем на данном наборе данных принципиально не решается без дополнительной ручной разметки.

5.3. Неоднородность пространственного разрешения. В отличие от первоначального датасета со стандартизированными размерами, реальные снимки имеют 67 различных разрешений — от 224×224 до 1024×1024 пикселей. Это потребовало введения обязательной нормализации: приведения всех изображений к единому размеру 256×256 пикселей перед извлечением признаков.

5.4. Несовместимость цветовых режимов. Аугментированная часть датасета содержит трёхканальные RGB-изображения вместо ожидаемых

одноканальных grayscale. Для единообразия обработки все изображения приводились к полутоновому виду.

5.5. Неприменимость ОА-специфических признаков. Пять признаков из исходного набора (*bone_area_ratio*, *cartilage_area_ratio*, *joint_space_width*, *osteophyte_score*, *sclerosis_index*) описывают морфологические структуры, характерные исключительно для остеоартрита. На аксиальных снимках мениска данные структуры либо отсутствуют в кадре, либо не выражены — вычисление указанных признаков лишено смысла и вносило бы шум в модель.

6. ВЫПОЛНЕННАЯ РАБОТА ПО АДАПТАЦИИ И ПЕРЕОБУЧЕНИЮ

6.1. Концепция адаптации

На основании проведённого анализа принята концепция адаптации без полного демонтажа существующей инфраструктуры. Алгоритм двойного порога Оцу с морфологической постобработкой сохранён в качестве самостоятельного инструмента визуализации тканей в режиме инференса — без предъявления требований к точности сегментации. Классификатор полностью переобучен под новую задачу с заменой признакового пространства.

6.2. Разработка модуля извлечения признаков

Разработан специализированный программный модуль `src/meniscus_features.py`, реализующий извлечение 20 признаков из полутоновых МРТ-изображений, предварительно приводимых к размеру 256×256 пикселей. По сравнению с первоначальным набором: **15**

универсальных признаков сохранены (они достаточно обобщены и информативны для любой МРТ-текстуры), **5 ОА-специфических признаков заменены** 5 новыми признаками, специфичными для диагностики надрыва мениска (таблица 5).

Таблица 5 — Признаковое пространство: сравнение исходного и адаптированного наборов

№	Признак	Описание	Статус
1	<i>mean_intensity</i>	Среднее значение яркости пикселей	Сохранён
2	<i>std_intensity</i>	Стандартное отклонение яркости	Сохранён
3	<i>skew_intensity</i>	Асимметрия гистограммы яркости	Сохранён
4	<i>kurt_intensity</i>	Экссесс гистограммы яркости	Сохранён
5	<i>laplacian_var</i>	Дисперсия лапласиана (мера резкости)	Сохранён
6	<i>fft_mean</i>	Среднее значение модуля спектра Фурье	Сохранён
7	<i>edge_density</i>	Плотность граней (детектор Канни)	Сохранён
8	<i>contrast</i>	Контраст (GLCM)	Сохранён

№	Признак	Описание	Статус
9	<i>homogeneity</i>	Однородность (GLCM)	Сохранён
10	<i>energy</i>	Энергия (GLCM)	Сохранён
11	<i>correlation</i>	Корреляция (GLCM)	Сохранён
12	<i>entropy</i>	Энтропия гистограммы яркости	Сохранён
13	<i>mean_gradient</i>	Среднее значение градиента (Собель)	Сохранён
14	<i>hist_peak_pos</i>	Нормированное положение пика гистограммы	Сохранён
15	<i>hist_spread</i>	Межквартильный размах гистограммы	Сохранён
16	<i>signal_void_ratio</i>	Доля тёмных пикселей (<30) — сигнальные пустоты при надрыве в T2	Новый *
17	<i>regional_asymmetry</i>	Нормированная разность яркости левой и правой половин снимка	Новый *
1	<i>center_brightness</i>	Средняя яркость центральной	Новый *

№	Признак	Описание	Статус
8		области (50% площади кадра)	
1 9	<i>peripheral_brightness</i>	Средняя яркость периферийного пояса (внешние 12%)	Новый *
2 0	<i>local_inhomogeneity</i>	Среднее локальных std в патчах 32×32 / глобальное std	Новый *

* — признаки разработаны в рамках данной работы; заменяют исходные OA-специфические признаки (*bone_area_ratio*, *cartilage_area_ratio*, *joint_space_width*, *osteophyte_score*, *sclerosis_index*).

6.3. Обучение бинарного классификатора на основе метода случайного леса

Переобученная модель сохраняет архитектуру метода случайного леса, однако целевая переменная изменена с KL-градации (0–4) на бинарную метку (0 — норма, 1 — надрыв). **Разбиение данных:** из оригинальной выборки (2 000 изображений) выполнено стратифицированное разбиение 70/15/15. Все 2 000 аугментированных изображений добавлены к обучающей выборке после приведения к grayscale. Итог: обучение — 3 400, валидация — 300, тест — 300 изображений. **Гиперпараметры:** деревьев — 300; выбор признаков — $\sqrt{n}$; веса классов — balanced; зерно — 42.

6.4. Интеграция классификатора в веб-приложение

Обученная модель интегрирована в веб-приложение FastAPI через новый эндпоинт POST /classify, принимающий MPT-изображение и

возвращающий JSON с предсказанным классом, уверенностью модели, вероятностью надрыва и топ-3 значимых признаков. В интерфейсе добавлена кнопка классификации и панель результата с цветовой индикацией (зелёный — норма, красный — надрыв) и полосовыми индикаторами вероятности.

7. РЕЗУЛЬТАТЫ И ОЦЕНКА КАЧЕСТВА

Оценка производилась на отложенных валидационной и тестовой выборках по метрикам Accuracy, Precision, Recall, F1-score и ROC-AUC (таблицы 6–8).

Таблица 6 — Итоговые метрики качества переобученного бинарного классификатора

Метрика	Валидационная выборка (n=300)	Тестовая выборка (n=300)
Accuracy	80,00%	78,67%
ROC-AUC	0,8739	0,8629
Precision, класс 0 — Норма	0,7679	0,7722
Recall, класс 0 — Норма	0,8600	0,8133
F1-score, класс 0 — Норма	0,8113	0,7922
Precision, класс 1 — Надрыв	0,8409	0,8028
Recall, класс 1 — Надрыв	0,7400	0,7600

Метрика	Валидационная выборка (n=300)	Тестовая выборка (n=300)
F1-score, класс 1 — Надрыв	0,7872	0,7808
Macro F1-score	0,7993	0,7865

Таблица 7 — Матрица ошибок на тестовой выборке

	Предсказано : Норма (0)	Предсказано : Надрыв (1)
Истинно: Норма (0)	122	28
Истинно: Надрыв (1)	36	114

Таблица 8 — Топ-10 наиболее значимых признаков по оценке Random Forest

Ра нг	Признак	Важность
1	<i>std_intensity</i>	0,0574
2	<i>kurt_intensity</i>	0,0573
3	<i>homogeneity</i>	0,0568
4	<i>correlation</i>	0,0544

Ранг	Признак	Важность
5	<i>local_inhomogeneity</i> *	0,0543
6	<i>center_brightness</i> *	0,0541
7	<i>mean_gradient</i>	0,0534
8	<i>skew_intensity</i>	0,0520
9	<i>regional_asymmetry</i> *	0,0520
10	<i>edge_density</i>	0,0508

* — новые признаки, разработанные специально для диагностики мениска; вошли в топ-10 по важности.

Полученные результаты свидетельствуют о приемлемом качестве переобученного классификатора для задачи скрининга: Accuracy ~79%, ROC-AUC ~0,86. Примечательно, что три из пяти новых специфических признаков (*local_inhomogeneity*, *center_brightness*, *regional_asymmetry*) вошли в топ-10 по важности, что подтверждает их информативность для данной задачи. Ведущую роль играют признаки неоднородности тканей, что согласуется с физической природой МРТ-сигнала: повреждение менисковой ткани проявляется локальными зонами изменённой интенсивности.

8. ЗАКЛЮЧЕНИЕ

В ходе выполнения настоящей работы решён комплекс научно-технических задач, охватывающих полный цикл разработки системы

машинного обучения в условиях изменения данных в процессе работы.

На первом этапе была реализована система классификации степени остеоартрита по шкале Kellgren–Lawrence с использованием алгоритма случайного леса и 20 признаков, включая специализированные морфологические характеристики. На втором этапе, после получения реального датасета KneeMRI-Meniscus-Dataset, был проведён его систематизированный анализ, выявивший шесть принципиальных несоответствий между новыми данными и исходной постановкой задачи. В ответ на это задача была переформулирована в задачу бинарной классификации надрыва мениска, признаковое пространство адаптировано путём замены пяти ОА-специфических признаков пятью новыми, специфичными для диагностики мениска. Переобученный классификатор достиг Accuracy = 78,7% и ROC-AUC = 0,863 на тестовой выборке из 300 изображений и интегрирован в существующую FastAPI-систему.

Направления дальнейшего развития: применение сверточных нейронных сетей (ResNet, EfficientNet) для повышения точности классификации; использование Grad-CAM для визуализации диагностически значимых областей; получение датасета с пиксельными масками сегментации мениска для обучения модели сегментации с учителем.